Concessão de Crédito

ID	Age	Income	CreditScore	LoanAmount	PaymHistory	Class	Prediction	PredictionAccuracy
1	35	75000	720	25000	0	good	good	Correto
2	28	48000	650	15000	2	bad	bad	Correto
3	42	85000	710	35000	1	good	good	Correto
4	52	120000	680	50000	3	bad	good	Incorreto
5	38	60000	640	15000	0	good	good	Correto
6	29	50000	590	10000	4	bad	bad	Correto
7	47	92000	750	45000	1	good	bad	Incorreto
8	31	55000	600	20000	3	bad	good	Incorreto
9	45	100000	730	30000	0	good	good	Correto
10	39	67000	625	18000	2	bad	bad	Correto

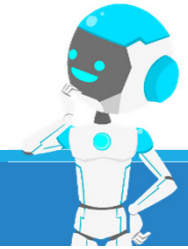

Matriz de Confusão (Classificação)

ID	Class	Prediction	PredictionAccuracy	
1	good	good	Correto	VP
2	bad	bad	Correto	VN
3	good	good	Correto	VP
4	bad	good	Incorreto	FP
5	good	good	Correto	VP
6	bad	bad	Correto	VN
7	good	bad	Incorreto	FN
8	bad	good	Incorreto	FP
9	good	good	Correto	VP
10	bad	bad	Correto	VN

	Classe Real Positiva	Classe Real Negativa
Classe Prevista Positiva	Verdadeiros Positivos	Falsos Negativos
Classe Prevista Negativa	Falsos Positivos	Verdadeiros Negativos

	Verd. Good	Verd. Bad
Prev Good	4	1
Prev Bad	2	3

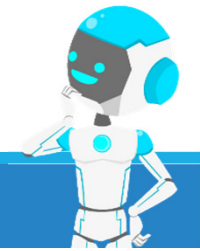

Acurácia

	Classe Real Positiva	Classe Real Negativa
Classe Prevista Positiva	Verdadeiros Positivos	Falsos Negativos
Classe Prevista Negativa	Falsos Positivos	Verdadeiros Negativos

	Verd. Good	Verd. Bad
Prev Good	4	1
Prev Bad	2	3

Classificações corretas

Formula: (VP + VN) / (VP + VN + FP + FN)
Calculation: (4 + 3) / (4 + 3 + 2 + 1) = 7 / 10 = 0.7
Interpretação: O modelo classificou corretamente 70% das instâncias

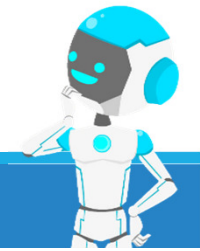

Precisão

A proporção de instâncias verdadeiramente positivas entre as instâncias previstas como positivas.
Fórmula: VP / (VP + FP)
Cálculo: 4 / (4 + 2) = 4 / 6 =0,67
Interpretação: Das instâncias previstas como positivas, 67% eram realmente positivas.

ID	Class	Prediction	PredictionAccuracy	
1	good	good	Correto	VP
2	bad	bad	Correto	VN
3	good	good	Correto	VP
4	bad	good	Incorreto	FP
5	good	good	Correto	VP
6	bad	bad	Correto	VN
7	good	bad	Incorreto	FN
8	bad	good	Incorreto	FP
9	good	good	Correto	VP
10	bad	bad	Correto	VN

	Classe Real Positiva	Classe Real Negativa
Classe Prevista Positiva	Verdadeiros Positivos	Falsos Negativos
Classe Prevista Negativa	Falsos Positivos	Verdadeiros Negativos

	Verd. Good	Verd. Bad
Prev Good	4	1
Prev Bad	2	3

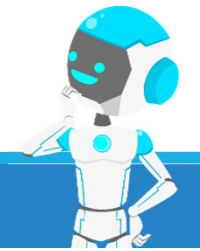

Recall

Recall (Sensibilidade ou Taxa de Verdadeiros Positivos): A proporção de instâncias classificadas como positivas em relação às instâncias positivas reais.
Fórmula: VP / (VP + FN)
Cálculo: 4 / (4 + 1) = 4 / 5 = 0,8
Interpretação: O modelo identificou corretamente 80% das instâncias boas.

ID	Class	Prediction	PredictionAccuracy	
1	good	good	Correto	VP
2	bad	bad	Correto	VN
3	good	good	Correto	VP
4	bad	good	Incorreto	FP
5	good	good	Correto	VP
6	bad	bad	Correto	VN
7	good	bad	Incorreto	FN
8	bad	good	Incorreto	FP
9	good	good	Correto	VP
10	bad	bad	Correto	VN

	Classe Real Positiva	Classe Real Negativa
Classe Prevista Positiva	Verdadeiros Positivos	Falsos Negativos
Classe Prevista Negativa	Falsos Positivos	Verdadeiros Negativos

	Verd. Good	Verd. Bad
Prev Good	4	1
Prev Bad	2	3

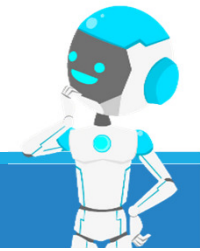

Especificidade

Especificidade: A proporção de instâncias negativas verdadeiras das instâncias negativas reais.
Fórmula: VN / (VN + FP)
Cálculos: 3 / 3+2) = 3/5 = 0,60
Interpretação: Identificou corretamente 75% das instâncias negativas como negativas

ID	Class	Prediction	PredictionAccuracy	
1	good	good	Correto	VP
2	bad	bad	Correto	VN
3	good	good	Correto	VP
4	bad	good	Incorreto	FP
5	good	good	Correto	VP
6	bad	bad	Correto	VN
7	good	bad	Incorreto	FN
8	bad	good	Incorreto	FP 1
9	good	good	Correto	VP
10	bad	bad	Correto	VN

	Classe Real Positiva	Classe Real Negativa
Classe Prevista Positiva	Verdadeiros Positivos	Falsos Negativos
Classe Prevista Negativa	Falsos Positivos	Verdadeiros Negativos

	Verd. Good	Verd. Bad
Prev Good	4	1
Prev Bad	2	3

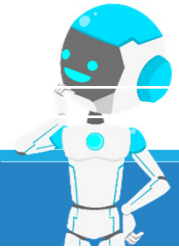

F1 Score

F1 Score: A média harmônica de precisão e recall
Formula: 2 * (Precisão * Recall) / (Precisãoo + Recall)
Cálculo: 2 * (0.67 * 0.8) / (0.67 + 0.8) = 2 * (0.536) / 1.47 = 0.73
Interpretação: 0.73 Indica que há um equilibrio entre precisão e recall

	Classe Real Positiva	**Classe Real Negativa**
Classe Prevista Positiva	**Verdadeiros Positivos**	**Falsos Negativos**
Classe Prevista Negativa	**Falsos Positivos**	**Verdadeiros Negativos**

	Verd. Good	**Verd. Bad**
Prev Good	**4**	**2**
Prev Bad	**1**	**3**

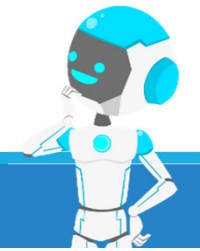

ROC

Quanto mais próximo de 1, melhor é a performance do modelo

O gráfico ROC (Receiver Operating Characteristic) e a métrica Area Under the ROC Curve (AUC-ROC) são usados para avaliar a performance de classificação binária.

O AUC-ROC pode variar entre 0 e 1. Quanto mais próximo de 1, melhor a performance do classificador.

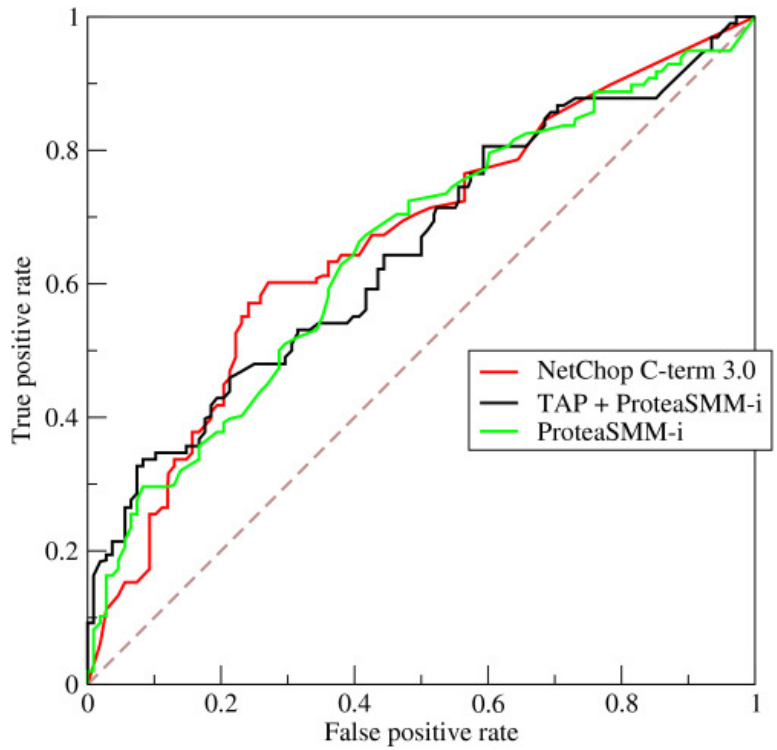

Problema da Classe Rara

1 milhões de transações
5% fraudulentas

Amostragem Aleatória
sem reposição: 1%

10.000
9.900 - Legítimas
100 - Fraudulentas

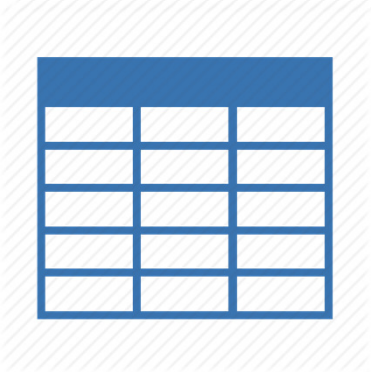

1 milhões de transações
5% fraudulentas

Amostragem Aleatória
sem reposição:
0,5% - Legítimas
0,5% - Fraudulentas

10.000
5.000 - Legítimas
5.000 - Fraudulentas

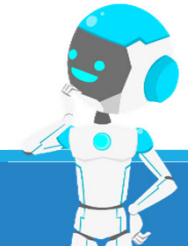

Não devemos olhar apenas acurácia!

Caso 1: Dataset desabalanceado

- 990 bad
- 10 good

Modelo sempre classifica tudo como bad

- Acurácia: 99% **990 + 0/1000 =**
- Recall: 0% **0 / 0 + 0 = 0**

	Classe Real Positiva	**Classe Real Negativa**
Classe Prevista Positiva	**Verdadeiros Positivos**	**Falsos Negativos**
Classe Prevista Negativa	**Falsos Positivos**	**Verdadeiros Negativos**

	Verd. Good	**Verd. Bad**
Prev Good	**0**	**0**
Prev Bad	**10**	**990**

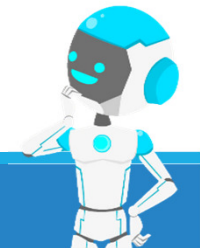

Não devemos olhar apenas acurácia!

Caso 1: Custos Diferentes
Doença Rara

- 950 Saudável
- 50 Doente

Métricas

- Acurácia: 96%
- Precisão: 67%
- Recall: 40%
- F1 Score: 50%

	Classe Real Positiva	**Classe Real Negativa**
Classe Prevista Positiva	**Verdadeiros Positivos**	**Falsos Negativos**
Classe Prevista Negativa	**Falsos Positivos**	**Verdadeiros Negativos**

	Verd. Saudável	**Verd. Doente**
Prev Saudável	**950**	**30**
Prev Doente	**10**	**20**

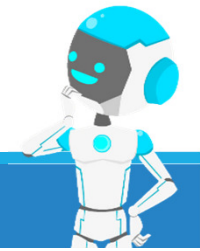

Problemas de Atributos Desconhecidos

No treino: regiões “Sul”, “Sudeste”, “Centro-Oeste” e “Norte”
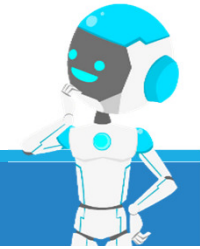
Na produção: região “Nordeste”